

Inteligencia Artificial Generativa

Modelos de Difusión

Franz Mayr

Universidad ORT Uruguay

mayr@ort.edu.uy

3 de noviembre de 2025


Introducción

- ▶ Los modelos de difusión son una clase de modelos generativos probabilísticos.
- ▶ Idea principal: comenzar con ruido y refinarlo gradualmente para generar datos, como imágenes.
- ▶ Aplicaciones recientes: generación de imágenes, eliminación de ruido y síntesis de video.

¿Por qué Modelos de Difusión?

- ▶ Alternativa poderosa a GANs y VAEs para generar datos de alta calidad.
- ▶ Ventajas: entrenamiento estable y producción de salidas diversas y realistas.

Idea general



Fuente: <https://lilianweng.github.io/posts/2021-07-11-diffusion-models/>

Proceso de Difusión Hacia Adelante


Dado un punto de datos muestreado de una distribución real $\mathbf{x}_0 \sim q(\mathbf{x})$, definimos un *proceso de difusión hacia adelante* en el cual añadimos pequeñas cantidades de ruido Gaussiano a la muestra en T pasos, produciendo una secuencia de muestras ruidosas $\mathbf{x}_1, \dots, \mathbf{x}_T$.

- ▶ Cronograma de varianza $\{\beta_t \in (0, 1)\}_{t=1}^T$.
- ▶ Distribución de transición:

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I})$$

$$q(\mathbf{x}_{1:T} | \mathbf{x}_0) = \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1})$$

Proceso de Difusión Hacia Adelante



- ▶ La muestra de datos $\mathbf{x}_0$ pierde gradualmente sus características distinguibles a medida que el paso t aumenta.
- ▶ Eventualmente, cuando $T \rightarrow \infty$, $\mathbf{x}_T$ es equivalente a una distribución Gaussiana isotrópica.

Fuente: Denoising Diffusion Probabilistic Models, Ho et al. (2020) <https://arxiv.org/pdf/2006.11239>

Proceso de Difusión Hacia Adelante


Una propiedad notable del proceso hacia adelante es que permite muestrear $\mathbf{x}_t$ en un paso de tiempo t arbitrario en forma cerrada.

- ▶ Usando la notación $\alpha_t := 1 - \beta_t$ y $\bar{\alpha}_t := \prod_{s=1}^t \alpha_s$, podemos expresar $q(\mathbf{x}_t|\mathbf{x}_0)$ como:

$$q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I})$$

- ▶ Esto significa que podemos muestrear $\mathbf{x}_t$ directamente desde $\mathbf{x}_0$ sin necesidad de iterar a través de todos los pasos intermedios.


Proceso de Difusión Reversa



Si podemos revertir el proceso anterior y muestrear de $q(\mathbf{x}_{t-1}|\mathbf{x}_t)$, seremos capaces de generar datos de la distribución real partir de una entrada de ruido Gaussiano $\mathbf{x}_T \sim \mathcal{N}(0, \mathbf{I})$.

- ▶ Si β_t es lo suficientemente pequeño, podemos asumir que $q(\mathbf{x}_{t-1}|\mathbf{x}_t)$ también será Gaussiano.
- ▶ Estimar $q(\mathbf{x}_{t-1}|\mathbf{x}_t)$ es muy difícil (*intractable*).
- ▶ Necesitamos aprender un modelo p_θ para aproximar estas probabilidades condicionales.

Proceso de Difusión Inversa - Ejemplo



Fuente: Deep Unsupervised Learning using Nonequilibrium Thermodynamics, Sohl-Dickstein et al. (2015)

<https://arxiv.org/pdf/1503.03585>

Aproximando el Proceso de Difusión Reversa

Para poder muestrear utilizando el proceso de difusión reversa, primero hay que aproximarlo:

$$p(\mathbf{x}_T) = \mathcal{N}(\mathbf{x}_T; \mathbf{0}; \mathbf{I})$$

$$p_{\theta}(\mathbf{x}_{0:T}) = p(\mathbf{x}_T) \prod_{t=1}^T p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t)$$

$$p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \mu_{\theta}(\mathbf{x}_t, t), \Sigma_{\theta}(\mathbf{x}_t, t))$$

Interpretación: El proceso de difusión reversa se modela como una cadena de pasos gaussianos parametrizados por θ . Cada paso busca invertir la adición de ruido realizada durante la difusión hacia adelante.

¿Cómo entrenamos?

El entrenamiento de los modelos de difusión se realiza optimizando la cota variacional en la log-verosimilitud negativa:

$$\mathbb{E}[-\log p_{\theta}(\mathbf{x}_0)] \leq \mathbb{E}_q \left[-\log \frac{p_{\theta}(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right] =: \mathcal{L}_{VLB}$$

- ▶ La función de pérdida $\mathcal{L}$ se optimiza para minimizar la diferencia entre la distribución generada p_{θ} y la verdadera distribución de datos.
- ▶ Esto se realiza a través de una combinación de términos de reconstrucción y regularización en cada paso de tiempo t .

Desglose de la Función de Pérdida VLB

La función de pérdida de la cota variacional inferior ($\mathcal{L}_{VLB}$) se descompone en términos específicos:

$$\mathcal{L}_{VLB} = L_T + L_{T-1} + \cdots + L_0$$

donde:

$$L_T = D_{\text{KL}}(q(\mathbf{x}_T|\mathbf{x}_0) \parallel p_\theta(\mathbf{x}_T))$$

$$L_t = D_{\text{KL}}(q(\mathbf{x}_t|\mathbf{x}_{t+1}, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_t|\mathbf{x}_{t+1})) \quad \text{para } 1 \leq t \leq T-1$$

$$L_0 = -\log p_\theta(\mathbf{x}_0|\mathbf{x}_1)$$

- ▶ Cada término L_t representa un paso en el proceso de difusión reversa.
- ▶ L_0 es un término de reconstrucción que mide la probabilidad de recuperar la muestra original.

Cálculo de Términos KL en la Función de Pérdida VLB

Cada término de divergencia KL en $\mathcal{L}_{VLB}$, excepto L_0 , compara dos distribuciones Gaussianas y puede calcularse en forma cerrada.

- ▶ $L_{\mathcal{T}}$ es constante y puede ignorarse durante el entrenamiento ya que q no tiene parámetros aprendibles y $\mathbf{x}_{\mathcal{T}}$ es ruido Gaussiano.
- ▶ Los términos intermedios L_t miden la discrepancia en cada paso de la aproximación de q por p_{θ} .

Esto simplifica el cálculo de la función de pérdida y permite un entrenamiento más eficiente.

De la formulación variacional a la implementación práctica

En la práctica, el entrenamiento de los modelos de difusión se simplifica notablemente:

$$\mathcal{L}_{VLB} \approx \mathbb{E}_{t, \mathbf{x}_0, \epsilon} \left[\|\epsilon - \epsilon_{\theta}(\mathbf{x}_t, t)\|^2 \right]$$

- ▶ Bajo las suposiciones de Ho et al. (2020), las varianzas Σ_{θ} se fijan y los términos de la cota se simplifican.
- ▶ El entrenamiento se reduce a una **pérdida de predicción de ruido (MSE)**, que corresponde al término dominante de la VLB.
- ▶ Esta formulación es eficiente, estable y conceptualmente equivalente a maximizar la log-verosimilitud de los datos bajo un modelo gaussiano.

Fuente: Ho, J., Jain, A., Abbeel, P. (2020). Denoising Diffusion Probabilistic Models. NeurIPS 2020.

<https://arxiv.org/pdf/2006.11239>

Entrenamiento con SGD en modelos de difusión

Objetivo: minimizar la cota variacional (VLB)

$$\min_{\theta} \mathcal{L}_{\text{VLB}}(\theta) \approx \min_{\theta} \mathbb{E}_{\mathbf{x}_0, t, \epsilon} [\|\epsilon - \epsilon_{\theta}(\mathbf{x}_t, t)\|^2]$$

Procedimiento:

1. Se muestrea una imagen real $\mathbf{x}_0 \sim p_{\text{data}}$
2. Se elige un paso de tiempo $t \sim \text{Uniform}(1, T)$
3. Se agrega ruido gaussiano: $\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$
4. Se predice el ruido con la red: $\hat{\epsilon} = \epsilon_{\theta}(\mathbf{x}_t, t)$
5. Se calcula la pérdida MSE: $\mathcal{L}_t = \|\epsilon - \hat{\epsilon}\|^2$
6. Se actualizan los parámetros con **SGD**:

$$\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}_t$$

Intuición: SGD ajusta los parámetros θ para que la red aprenda a predecir el ruido añadido en cada paso de difusión, lo que equivale a aprender a invertir el proceso de degradación.

Bibliografía

- ▶ Sohl-Dickstein, J., Weiss, E., Maheswaranathan, N., y Ganguli, S. (2015). "Deep Unsupervised Learning using Nonequilibrium Thermodynamics." Disponible en: <https://arxiv.org/pdf/1503.03585>
- ▶ Ho, J., Jain, A., y Abbeel, P. (2020). "Denoising Diffusion Probabilistic Models." Disponible en: <https://arxiv.org/pdf/2006.11239>
- ▶ Lilian Weng. (2021). "Diffusion Models." Disponible en: <https://lilianweng.github.io/posts/2021-07-11-diffusion-models/>