

# Inteligencia Artificial Generativa

## Evaluación de modelos generativos

Franz Mayr

Universidad ORT Uruguay  
[mayr@ort.edu.uy](mailto:mayr@ort.edu.uy)

4 de noviembre de 2025

# Evaluar modelos generativos: el desafío

En modelos **discriminativos**, evaluamos con métricas claras (accuracy, F1, etc.) al comparar predicciones con etiquetas verdaderas.

En cambio, en modelos **generativos** el objetivo es aproximar una distribución completa:

$$p_{\theta}(x) \approx p_{\text{data}}(x)$$

No existen etiquetas “correctas”: sólo queremos que las muestras sean coherentes y diversas.

**Problema:** ¿cómo medimos qué tan “parecida” es una distribución aprendida a los datos reales?

# El problema formal de la evaluación

Queremos medir cuán cerca está la distribución generada  $p_{\theta}(x)$  de la real  $p_{\text{data}}(x)$ .

$D(p_{\theta}, p_{\text{data}})$  “distancia entre distribuciones”

- ▶  $p_{\text{data}}$  no es accesible: sólo tenemos muestras del conjunto de entrenamiento.
- ▶ Las distancias en espacios de alta dimensión son difíciles de estimar.
- ▶ La evaluación compara **conjuntos de muestras**, no ejemplos individuales.

**Conclusión:** no existe una métrica universal; distintas aproximaciones se usan según el modelo y el dominio.

# Fidelidad vs diversidad

En la práctica, la calidad de un modelo generativo se analiza en dos ejes principales:

| Dimensión  | Qué mide                                          | Ejemplo extremo                                            |
|------------|---------------------------------------------------|------------------------------------------------------------|
| Fidelidad  | Qué tan realistas son las muestras                | Reproduce fotos reales, pero repite patrones (overfitting) |
| Diversidad | Qué tanto cubre la variedad del conjunto de datos | Genera variedad, pero con artefactos o ruido               |

Un buen modelo equilibra ambos aspectos: fidelidad y diversidad.

# Comparando familias de modelos

Cada arquitectura generativa prioriza distintos aspectos de la distribución:

| <b>Modelo</b>   | <b>Propiedad típica</b>      | <b>Problema frecuente</b> |
|-----------------|------------------------------|---------------------------|
| VAE             | Amplia cobertura de modos    | Muestras borrosas         |
| GAN             | Alta fidelidad               | Colapso de modos          |
| Difusión        | Buena fidelidad y diversidad | Lento de muestrear        |
| Language Models | Coherencia contextual        | Sesgos y “alucinaciones”  |

Cada técnica equilibra de forma diferente fidelidad, diversidad y eficiencia.

# Consecuencias prácticas

- ▶ No hay una única forma de evaluar la calidad de un generador.
- ▶ La elección de la métrica depende del objetivo:
  - ▶ **Fidelidad:** qué tan realistas son las muestras.
  - ▶ **Diversidad:** qué tanto cubre la distribución de datos.
  - ▶ **Utilidad:** si las muestras sirven para tareas downstream.
- ▶ Esta complejidad motiva la creación de métricas específicas y heurísticas perceptuales.

# Referencias del bloque

- ▶ Theis, L., van den Oord, A., Bethge, M. (2015). A note on the evaluation of generative models. <https://arxiv.org/abs/1511.01844>
- ▶ Goodfellow, I., Bengio, Y., Courville, A. (2016). Deep Learning. MIT Press. Capítulo 20.14 (Evaluating Generative Models). <https://www.deeplearningbook.org/>

# Qué medimos (y qué no)

## Importante antes de empezar

En este bloque analizamos **métricas de evaluación**, no funciones de pérdida de entrenamiento.

- ▶ La loss define cómo aprende el modelo (p.ej., KL en VAE, adversarial en GAN).
- ▶ Las métricas miden qué tan bien se comporta el modelo ya entrenado.
- ▶ A veces provienen de la misma idea teórica (divergencias), pero cumplen roles distintos.

**Idea clave:** una cosa es cómo el modelo aprende, otra cómo lo evaluamos.



# Comparar distribuciones

Queremos cuantificar la diferencia entre la distribución real  $p_{\text{data}}$  y la generada  $p_{\theta}$ :

$$D(p_{\text{data}}, p_{\theta}) \approx \text{“cuán distintas son”}$$

- ▶ En general,  $D$  no es computable exactamente en alta dimensión.
- ▶ Usamos **divergencias** (por lo general no simétricas) o **distancias** (simétricas, métricas en sentido geométrico).
- ▶ La elección de  $D$  influye en estabilidad, calidad y diversidad de las muestras.

# Divergencias basadas en probabilidad

Estas métricas comparan distribuciones según sus probabilidades punto a punto.

- **Divergencia KL (Kullback–Leibler)** Mide cuánto se “pierde” al usar  $q(x)$  para aproximar  $p(x)$ :

$$D_{\text{KL}}(p\|q) = \int p(x) \log \frac{p(x)}{q(x)} dx$$

- ▶ Es asimétrica:  $D_{\text{KL}}(p\|q) \neq D_{\text{KL}}(q\|p)$ .
- ▶ Penaliza fuertemente cuando  $q(x)$  subestima a  $p(x)$ .
- ▶ Aparece en VAEs y en máxima verosimilitud.
- **Divergencia JS (Jensen–Shannon)** Promedio simétrico de dos KL divergences:

$$D_{\text{JS}}(p\|q) = \frac{1}{2}D_{\text{KL}}(p\|m) + \frac{1}{2}D_{\text{KL}}(q\|m), \quad m = \frac{1}{2}(p + q)$$

- ▶ Es finita y simétrica.
- ▶ Es la medida subyacente en los GANs originales.

# Distancias geométricas y basadas en muestras

Estas métricas miden diferencias en el espacio de las muestras, no solo en probabilidad.

- **Distancia Wasserstein** Mide el “costo de transporte” necesario para convertir  $p$  en  $q$ . Se define como:

$$W(p, q) = \inf_{\gamma \in \Pi(p, q)} \mathbb{E}_{(x, y) \sim \gamma} [\|x - y\|]$$

- ▶ Ofrece gradientes más estables que la KL o JS.
- ▶ Usada en los **WGAN**, mejora el entrenamiento de GANs.

- **MMD (Maximum Mean Discrepancy)** Compara las medias de  $p$  y  $q$  en un espacio de características definido por un kernel:

$$\text{MMD}^2(p, q) = \|\mu_p - \mu_q\|_{\mathcal{H}}^2$$

- ▶ No requiere conocer las densidades explícitas.
- ▶ Puede estimarse directamente a partir de muestras.
- ▶ Se usa en MMD-GANs y modelos basados en kernels.

# Inception Score (IS)

**Propósito:** medir **fidelidad** y **diversidad** en imágenes generadas usando un clasificador preentrenado (Inception v3).

$$\text{IS} = \exp\left(\mathbb{E}_{x \sim p_g}[D_{\text{KL}}(p(y|x) \parallel p(y))]\right)$$

- ▶ Alta **fidelidad**: cada imagen  $x$  produce una predicción  $p(y|x)$  “confiable”.
- ▶ Alta **diversidad**: la distribución marginal  $p(y)$  tiene alta entropía.
- ▶ No necesita imágenes reales, sólo las generadas.

**Limitación:** depende del dominio y del modelo Inception; no siempre correlaciona con percepción humana.

# Fréchet Inception Distance (FID)

**Propósito:** comparar la distribución de embeddings de **imágenes reales** y **generadas**.

$$\text{FID} = \|\mu_r - \mu_g\|_2^2 + \text{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2})$$

- ▶  $\mu_r, \Sigma_r$ : media/covarianza de features reales;  $\mu_g, \Sigma_g$ : de features generadas.
- ▶ Features: penúltima capa de Inception v3.
- ▶ FID bajo  $\rightarrow$  distribuciones más parecidas  $\rightarrow$  mejor calidad/diversidad.

**Nota:** requiere un conjunto de imágenes reales de referencia.

# Precision y Recall para Modelos Generativos

**Propósito:** separar dos aspectos que FID combina: **fidelidad** (precision) y **diversidad** (recall).

- ▶ Propuesto por Sajjadi et al., NeurIPS 2018.
- ▶ Representa imágenes reales y generadas como puntos en un espacio de embeddings (p.ej. Inception).
- ▶ Calcula dos proporciones:
  - ▶ **Precision:** fracción de muestras generadas que caen cerca de alguna real → mide realismo.
  - ▶ **Recall:** fracción de muestras reales que tienen una generada cercana → mide cobertura/diversidad.
- ▶ Puede graficarse como curva PR o área bajo la curva (F-score).

**Ventaja:** permite visualizar trade-offs fidelidad vs diversidad.

## Perplexity (PPL)

**Propósito:** medir la **fluidez probabilística** de un modelo de lenguaje. Evalúa cuán bien predice la secuencia real el modelo  $p_{\theta}(x)$ .

$$\text{PPL} = \exp\left(-\frac{1}{N} \sum_{i=1}^N \log p_{\theta}(x_i)\right)$$

- ▶ Equivale a la exponencial de la entropía cruzada promedio.
- ▶ Cuanto menor la PPL, más alta la probabilidad asignada a las palabras reales.
- ▶ Es una métrica **intrínseca**: usa las probabilidades del modelo, no necesita generar texto.

### Limitaciones:

- ▶ No evalúa coherencia global ni factualidad.
- ▶ Puede favorecer modelos que “predicen bien” pero generan texto redundante.

# BLEU (Bilingual Evaluation Understudy)

**Propósito:** medir la **precisión literal** del texto generado respecto a una o varias referencias humanas.

$$\text{BLEU} = \text{BP} \cdot \exp\left(\sum_{n=1}^N w_n \log p_n\right)$$

- ▶  $p_n$ : precisión de n-gramas (fracción de n-gramas generados que aparecen en referencias).
- ▶  $w_n$ : pesos (usualmente  $1/N$ ); BLEU-4 usa  $N = 4$ .
- ▶  $C$ : longitud total del texto generado;  $R$ : longitud total de las referencias.
- ▶ BP (brevity penalty): penaliza salidas cortas  $\text{BP} = 1$  si  $C > R$ ,  
 $\text{BP} = \exp(1 - R/C)$  si  $C \leq R$ .

**Interpretación:** BLEU alto  $\rightarrow$  coincidencias exactas y longitud adecuada.  
BLEU bajo  $\rightarrow$  texto diferente o demasiado corto. No evalúa sinonimia ni significado.



## BLEU: ejemplo paso a paso ( $N=2$ , $w_1 = w_2 = \frac{1}{2}$ )

**Referencia (R):** el gato negro duerme ( $R = 4$  tokens)

**Generado (C):** el gato duerme ( $C = 3$  tokens)

**Unigramas ( $n=1$ ):** el, gato, duerme  $\Rightarrow 3/3$  coinciden  $\Rightarrow p_1 = 1,0$

**Bigramas ( $n=2$ ):**

ref = {el gato, gato negro, negro duerme}

gen = {el gato, gato duerme}

$\Rightarrow 1/2$  coinciden (el gato)  $\Rightarrow p_2 = 0,5$

**Penalización por brevedad (BP):**

$C = 3 < R = 4 \Rightarrow BP = \exp(1 - \frac{R}{C}) = \exp(1 - \frac{4}{3}) = \exp(-\frac{1}{3}) \approx 0,7165$

**Media geométrica de precisiones:**

$$\exp\left(\frac{1}{2} \log p_1 + \frac{1}{2} \log p_2\right) = \exp\left(\frac{1}{2}(0 + \log 0,5)\right) = \exp(-0,3466) \approx 0,7071$$

**BLEU final:**  $BLEU = BP \times 0,7071 \approx 0,7165 \times 0,7071 \approx 0,507$

**Lectura:** alta precisión en unigramas, pero la frase es corta y pierde bigramas  $\Rightarrow BP < 1$  y  $p_2 < 1$ .

# ROUGE (Recall-Oriented Understudy)

**Propósito:** medir la **cobertura informativa** del texto generado respecto al contenido de la referencia (enfoque de **recall**).

**Principales variantes:**

- ▶ **ROUGE-N:** recall de n-gramas

$$\text{ROUGE-N} = \frac{\# \text{ n-gramas comunes}}{\# \text{ n-gramas en la referencia}}$$

- ▶ **ROUGE-L:** Longest Common Subsequence (LCS) mide la subsecuencia común más larga entre generado y referencia.
- ▶ **ROUGE-F:** F1 entre precisión y recall de n-gramas.

**Interpretación:** ROUGE alto → el texto generado cubre gran parte de la información de la referencia. Evalúa cobertura, no exactitud literal ni coherencia semántica.

**Uso típico:** resumen automático, QA generativo y evaluación de textos condicionales.

## ROUGE: ejemplo paso a paso (ROUGE-1 y ROUGE-L)

**Referencia (R):** el gato negro duerme

**Generado (G):** el gato duerme

**ROUGE-1 (recall de unigramas):**

$$\text{ROUGE-1} = \frac{\# \text{ unigramas comunes}}{\# \text{ unigramas en la referencia}} = \frac{3}{4} = 0,75$$

(el, gato, duerme aparecen en ambos; falta negro)

**ROUGE-L (longest common subsequence):**

$$\text{LCS}(R, G) = 3, \quad \text{ROUGE-L} = \frac{\text{LCS}}{\text{longitud de R}} = \frac{3}{4} = 0,75$$

**Lectura:**

- ▶ El texto generado cubre el 75 % de la información de la referencia.
- ▶ ROUGE penaliza la omisión de contenido (en este caso, negro).

**Idea clave:** BLEU mide precisión (“¿qué tanto de lo generado es correcto?”);  
ROUGE mide recall (“¿qué tanto de la referencia se cubrió?”).

# Métricas contextuales modernas

**Motivación:** BLEU y ROUGE miden coincidencia literal. Las métricas modernas buscan medir **similaridad semántica**: ¿el modelo transmite el mismo significado aunque use otras palabras?

**Idea general:** representar textos como embeddings (p. ej. con BERT o CLIP) y medir **similitud coseno** entre ellos.

## Ejemplos:

- ▶ **BERTScore** — (Zhang et al., 2020) Compara embeddings token a token entre texto generado y referencia, promediando similitudes → Precision, Recall y F1 semánticos.
- ▶ **CLIPScore** — (Hessel et al., 2021) Usa CLIP para evaluar coherencia texto–imagen (captioning, text-to-image).
- ▶ **HPSv2 (Human Preference Score)** — (2023) Modelo aprendido para aproximar juicios humanos sobre pares de salidas.

**Ventajas:** capturan sinonimia y significado contextual.  
modelo base y heredan sus sesgos.

**Limitaciones:** dependen del

**Uso típico:** texto libre, diálogo, captioning y text-to-image.

# Limitaciones y advertencias

- ▶ Métricas basadas en features dependen del modelo preentrenado (Inception, BERT, CLIP).
- ▶ La correlación con percepción humana puede ser limitada.
- ▶ Las métricas de densidad son sensibles al espacio de representación (reparametrizaciones).
- ▶ Ninguna métrica cuantitativa captura ética, sesgo o utilidad práctica por sí sola.

**Conclusión:** las métricas cuantitativas son necesarias pero incompletas; deben complementarse con evaluación cualitativa y orientada a tareas.

**Tendencia:** las métricas evolucionan hacia la percepción humana y contextual.

# Referencias del bloque (I)

- ▶ Heusel, M., Ramsauer, H., Unterthiner, T., Nessler, B., & Hochreiter, S. (2017). GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium. (Propone el FID).  
<https://arxiv.org/abs/1706.08500>
- ▶ Sajjadi, M. S. M., Bachem, O., Lucic, M., Bousquet, O., & Gelly, S. (2018). Assessing Generative Models via Precision and Recall. NeurIPS 2018.  
<https://arxiv.org/abs/1806.00035>
- ▶ Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: a Method for Automatic Evaluation of Machine Translation. ACL 2002.  
<https://aclanthology.org/P02-1040/>
- ▶ Lin, C.-Y. (2004). ROUGE: A Package for Automatic Evaluation of Summaries. Workshop on Text Summarization, ACL 2004.  
<https://aclanthology.org/W04-1013/>

## Referencias del bloque (II)

- ▶ Zhang, T., Kishore, V., Wu, F., Weinberger, K., & Artzi, Y. (2020). BERTScore: Evaluating Text Generation with BERT. ICLR 2020. <https://arxiv.org/abs/1904.09675>
- ▶ Hessel, J., Holtzman, A., Forbes, M., Le Bras, R., & Choi, Y. (2021). CLIPScore: A Reference-free Evaluation Metric for Image Captioning. EMNLP 2021. <https://arxiv.org/abs/2104.08718>
- ▶ Wu, X., Hao, Y., Sun, K., Chen, Y., Zhu, F., Zhao, R., & Li, H. (2023). Human Preference Score v2: A Solid Benchmark for Evaluating Human Preferences of Text-to-Image Synthesis. arXiv:2306.09341. <https://arxiv.org/abs/2306.09341>

# Evaluación cualitativa y humana

**Motivación:** Las métricas automáticas no siempre reflejan la **percepción humana**. Un modelo puede tener FID o BLEU altos y aun así generar contenido incoherente o poco natural.

**Evaluación humana:** busca medir atributos percibidos como:

- ▶ **Naturalidad** y fluidez del texto o imagen.
- ▶ **Coherencia** y consistencia semántica.
- ▶ **Originalidad** o creatividad.
- ▶ **Fidelidad factual** (en LLMs) o **relevancia visual** (en difusión).

**Idea clave:** las métricas automáticas capturan diferencias estadísticas; las humanas capturan calidad percibida.



# Métodos de evaluación humana

## Formatos comunes:

- ▶ **Comparación por pares (A/B testing):** los evaluadores eligen entre dos salidas cuál prefieren según un criterio (realismo, coherencia, estilo...).
- ▶ **Escalas Likert:** cada salida se puntúa de 1 a 5 o 1 a 7 en distintos ejes (fluidez, claridad, atractivo...).
- ▶ **Ranking múltiple:** ordenar varias salidas del mejor al peor.
- ▶ **Turing-like tests:** ¿los humanos distinguen entre contenido real y generado?

## Aspectos prácticos:

- ▶ Tamaño de muestra y número de evaluadores.
- ▶ Consistencia entre evaluadores: **Cohen's  $\kappa$**  o **Krippendorff's  $\alpha$** .
- ▶ Coste y escalabilidad (crowdsourcing vs. expertos).

**Ventaja:** correlaciona mejor con percepción humana. **Desventaja:** es costosa y subjetiva.

# Correlación con métricas automáticas

## Preguntas clave:

- ▶ ¿Qué tan bien predicen las métricas automáticas la preferencia humana?
- ▶ ¿Existe una métrica “universal” que correlacione en todos los dominios?

## Hallazgos comunes:

- ▶ BLEU/ROUGE correlacionan débilmente con evaluaciones humanas en tareas abiertas.
- ▶ FID e Inception Score correlacionan solo parcialmente con juicios de realismo.
- ▶ BERTScore, CLIPScore y HPSv2 muestran mejor correlación, pero dependen del modelo base.

**Tendencia actual:** combinar métricas automáticas + evaluación humana + criterios orientados a tareas.

**Idea final:** lo que importa no es solo “qué tan real parece”, sino “qué tan útil o convincente resulta para un humano”.

## Referencias del bloque (Texto)

- ▶ Celikyilmaz, A., Clark, E., & Gao, J. (2020). Evaluation of Text Generation: A Survey. arXiv preprint <https://arxiv.org/abs/2006.14799>
- ▶ Clark, E., Ross, A., Ji, A., Balasubramanian, D., Bhagavatula, C., Tsvetkov, Y., & Choi, Y. (2021). All That's "Human" Is Not Gold: Evaluating Human Evaluation of Generated Text. ACL 2021.  
<https://arxiv.org/abs/2107.00061>
- ▶ van der Lee, C., Gatt, A., van Miltenburg, E., & Krahmer, E. (2021). Human evaluation of automatically generated text: Current trends and best practice guidelines. Computer Speech & Language, 67, 101151. <https://www.sciencedirect.com/science/article/pii/S088523082030084X>

## Referencias del bloque (Imágenes)

- ▶ Zhou, B., Khosla, A., Lapedriza, A., Torralba, A., & Oliva, A. (2016). Places: An Image Database for Deep Scene Understanding. arXiv:1610.02055.  
<https://arxiv.org/abs/1610.02055>
- ▶ He, R., Sun, S., Yu, X., Xue, C., Zhang, W., Torr, P., Bai, S., & Qi, X. (2023). Is synthetic data from generative models ready for image recognition? ICLR 2023 (Spotlight), arXiv:2210.07574.  
<https://arxiv.org/abs/2210.07574>
- ▶ Wu, X., Hao, Y., Sun, K., Chen, Y., Zhu, F., Zhao, R., & Li, H. (2023). Human Preference Score v2: A Solid Benchmark for Evaluating Human Preferences of Text-to-Image Synthesis. arXiv:2306.09341.  
<https://arxiv.org/abs/2306.09341>

# Evaluación orientada a tareas

**Motivación:** Un modelo generativo no solo debe producir muestras “realistas”, sino ser **útil** en contextos concretos: mejorar desempeño, reducir costos o ampliar cobertura (variedad de casos).

**Idea central:** medir qué tan bien las representaciones o los datos generados contribuyen a una tarea downstream:

- ▶ Entrenamiento de clasificadores o detectores.
- ▶ Data augmentation con muestras sintéticas.
- ▶ Mejora de robustez o generalización.

**Ejemplo:** usar datos sintéticos de difusión para entrenar un modelo de visión; se evalúa el accuracy final, no el FID.

# Medir la utilidad en tareas downstream

## Estrategias comunes:

- ▶ **Fine-tuning evaluation:** entrenar un modelo con datos generados y medir su rendimiento en test reales.
- ▶ **Teacher–student consistency:** comparar predicciones entre un modelo base y uno entrenado con datos sintéticos.
- ▶ **Task-specific scores:** métricas estándares de la tarea (accuracy, F1, Recall, etc).

## Casos representativos:

- ▶ Is Synthetic Data from Generative Models Ready for Image Recognition? (He et al., ICLR 2023) — evalúa pre-entrenamiento de clasificadores con datos generados.
- ▶ En LLMs, métricas como **TruthfulQA**, **MMLU**, **HELM** miden factualidad, robustez y utilidad práctica.

**Conclusión:** la evaluación orientada a tareas revela valor práctico más allá de la estética o coherencia.

# Trade-offs en modelos generativos

## Ejes de evaluación interrelacionados:

- ▶ **Fidelidad vs diversidad:** calidad perceptual frente a cobertura de modos.
- ▶ **Precisión vs robustez:** desempeño óptimo frente a variación o ruido.
- ▶ **Utilidad vs costo:** beneficio práctico frente a complejidad computacional.

## Nuevas dimensiones:

- ▶ **Equidad y sesgo:** ¿afecta de forma balanceada a distintos grupos?
- ▶ **Seguridad:** resistencia a prompts o ataques adversarios.
- ▶ **Eficiencia y escalabilidad:** consumo de recursos, latencia y posibilidad de despliegue a gran escala.

**Evaluar modelos generativos** requiere equilibrar desempeño, robustez y eficiencia, considerando también aspectos de equidad y seguridad.